

可執行驗收支援的 LLM 程式代理交付

Vacant 的機制比較 複製實驗與可究責紀錄

Executable Acceptance Testing for LLM Code Agent Delivery

Mechanism Comparisons Replication Experiments and Accountability Records in Vacant

研究資料截至 2026 年 9 月 13 日 | 2026 年 9 月 14 日

摘要

大型語言模型程式代理可以產生程式碼，卻不能僅憑自我陳述建立交付品質的依據。本文研究在需求已有可執行驗收測資的條件下，如何區分額外取樣、驗收選擇與失敗回饋修訂所帶來的增益，並使交付過程留下可驗證紀錄。我們提出並評估 Vacant 的驗收與紀錄整合架構：以可見測資決定出貨或拒交，以隔離的隱藏測資評估交付成功，並將驗收及修訂事件寫入簽章雜湊鏈。實驗以一個本地 12B 量化模型，比較單次生成、最多五次生成的驗收重抽、五候選多數決，以及三種修訂流程；分析涵蓋同題庫五次新種子複製與四個跨題庫題目集。五次複製中，三種修訂流程對單次生成的十五項比較均通過各次實驗內的 Holm 校正；驗收加重抽對單次生成的配對增益為 14.17 至 19.17 個百分點。主要修訂流程 H-MIX 相對驗收重抽的差值依次為 +5.83、+4.17、+0.83、+2.50 與 +4.31 個百分點，五次均為正，但零次通過 Holm 校正。跨題庫 716 題的 H-MIX 相對驗收重抽差值為 +1.12 個百分點，校正後 $p = .3409$ ；相對單次生成則為 +7.96 個百分點，校正後 $p = 2.02 \times 10^{-8}$ 。另有 194 條已保存收據鏈的 9,841 筆紀錄通過逐筆驗簽。結果支持在本實驗條件下以可執行驗收與重抽建立交付依據，但尚未確立修訂相對重抽的額外效益。本文的貢獻是可審計的機制比較與研究紀錄整合；有限測資、單一模型、重複題目與混合推論後端仍限制外推。

關鍵詞：大型語言模型；程式代理；可執行驗收；修訂迴圈；配對實驗；複製研究；可究責性

Abstract

LLM code agents can generate programs, but their own claims of correctness do not establish a sound basis for delivery. We investigate how additional sampling, executable selection, and feedback-driven revision contribute to successful delivery when requirements are already represented by executable acceptance tests. Vacant integrates a visible-test delivery gate with hidden-test evaluation and signed hash-chain records. Using one locally hosted, quantized 12B model, we compare single-shot generation, gated resampling with up to five calls, five-candidate majority selection, and three revision workflows. The evaluation includes five new-seed repetitions on the same 120-task bank and a separate four-set evaluation comprising 716 tasks. Across the five repetitions, all fifteen revision-versus-single-shot comparisons pass within-repetition Holm correction. Gated resampling improves over single-shot generation by 14.17 to 19.17 percentage points. However, the primary H-MIX workflow improves over gated resampling by only 5.83, 4.17, 0.83, 2.50, and 4.31 percentage points; none of these five comparisons passes Holm correction. Across benchmark sets, the pooled improvement is 1.12 percentage points over gated resampling (adjusted $p = .3409$) and 7.96 points over single-shot generation (adjusted $p = 2.02 \times 10^{-8}$). All 9,841 entries in 194 archived receipt chains pass signature verification. These findings support executable gating with resampling under the evaluated conditions, while the incremental benefit of revision remains unresolved. The contribution is an auditable integration and empirical comparison, rather than a new repair algorithm or a general guarantee of correctness. Limited test coverage, repeated tasks, a single model, and heterogeneous inference backends constrain generalization.

一 緒論

1.1 研究背景與問題

程式代理交付的對象不是一句回答，而是一份會被執行、修改或接入其他系統的產物。使用者因此面臨兩個不同問題：這份產物是否符合需求，以及發生爭議時能否重建當時的驗收與交付過程。前者涉及判定正確性的依據，後者涉及行為紀錄的可核驗性。即使兩者都由同一個系統提供，也不能用單一「可信度」分數取代。

軟體測試中的判定準則問題（test oracle problem）早已指出，產生輸入與執行程式不等於知道輸出是否正確；若缺少可用的規格、契約或其他判定依據，測試自動化仍需要人工判斷 [1]。大型語言模型使產生候選程式更加容易，卻沒有消除這個問題。以 HumanEval 為代表的評估使用測試判定功能正確性 [2]，EvalPlus 則顯示，原有測試不足時，錯誤程式會被當成正確程式，甚至影響模型排名 [3]。

本文把研究範圍限定在 Python 程式生成，而且假設使用者需求已經具有可執行驗收測資。我們不將自然語言需求完整轉換成測試，也不把測試通過當成任意真實情境中的正確性。這個限定使研究能回答一個可操作的問題：當同一個模型有額外生成機會時，應如何利用驗收結果決定交付，以及是否值得把失敗訊息交回模型要求修訂。

1.2 研究主題與定位

本文定調為「可執行驗收支援的 LLM 程式代理交付」，以 Vacant 為系統實作與實驗載體。核心對象是交付機制，而不是模型能力排行榜。比較的主軸包括單次生成、驗收加重抽、行為多數決與執行回饋修訂；簽章紀錄則提供另一條可獨立檢查的證據鏈。

我們採用「可究責性」描述特定金鑰所簽署事件的可追溯與可核驗性，使用「有依據的依賴」描述驗收結果對交付決策的支援。這些都是本文的操作性用語。研究沒有招募使用者，也沒有測量信任量表、依賴意願或監督行為，因而不以「提升人類信任」作為結果。Körber

的信任量測研究區分信任構念及其行為表現，亦提供問卷與效度檢查的具體方法 [15]；本文未執行這類測量。

這一定位不要求宣稱監督與信任在所有理論中互斥。舊有定義中的「不論監控能力如何」不足以推導「任何有監督的系統都不可能涉及信任」。本文選擇較窄的概念，是因為現有資料能測量交付與紀錄，不能測量心理信任。概念的範圍應由研究操作與證據決定。

1.3 研究問題與貢獻

本研究提出四個問題。第一，在可執行驗收存在時，交付增益有多少出現在驗收重抽階段，又有多少出現在回饋修訂階段？第二，固定候選集合後，可見測試閘門與行為多數決有何差異？第三，初次實驗中的修訂增益能否在同題庫新種子與不同題庫中再現？第四，簽章紀錄與多方執行能支持哪些可究責主張，又在哪些情況下失效？

本文提供三方面的貢獻：以共用呼叫上限與同候選比較控制部分成本和選擇差異；完整報告初次實驗、後續五次複製及跨題庫結果，使單次顯著不被提升成穩定效應；將逐次驗收、拒交與簽章紀錄接入同一個可重算流程，並揭露量具修正及後端事故。這些貢獻屬於系統整合與實證研究，不構成新修復演算法、完整形式化安全證明或整個領域首創的主張。

二 相關研究與研究缺口

2.1 可執行評估與測試充分性

Chen 等人的程式模型評估將功能測試與重複取樣結合，說明候選池中存在正解與單次輸出正確是不同事件 [2]。EvalPlus 藉由擴充測資揭露原始 HumanEval 未發現的錯誤 [3]。LiveCodeBench 持續收集競賽題目，並將程式生成、修復與執行等能力納入評估 [4]。這些工作提供本研究使用的評估基礎，但其原始論文結果不能直接作為 Vacant 的表現證據。

本研究使用的 MBPP+、HumanEval+ 與 LiveCodeBench 子集經過本地版本固定、沙箱適用性檢查與排除程序，分母不必等於原始資料集的完整大小。尤其本地 LCB v2、v3 是本專案

的題庫識別碼，不應直接視為外部排行榜的同名發布版。本文所有比率均對應本地題目集合，並在方法與附錄標示資料來源。

Barr 等人整理的判定準則問題，直接界定 Vacant 的適用前提 [1]。驗收開門可改善候選選擇，但其上限仍取決於測試代表需求的程度。多個執行器一致通過同一套不足的測試，也只表示執行一致，不會補足規格缺口。

2.2 取樣聚合與失敗回饋修訂

Self-consistency 透過多條推理路徑的答案聚合改善推理任務表現 [5]。本文的 OFF5 借用多次取樣後聚合的概念，但在程式任務上依可見執行的行為簽名分桶，因此是本研究的程式行為多數決基準，不是對原始 chain-of-thought 方法的完整重現。

Self-Debugging 研究利用程式解釋與執行結果引導模型修正 [6]；Reflexion 則將回饋及語言反思納入代理的後續嘗試 [7]。兩者已建立「把失敗資訊回送給模型」的研究脈絡。H-MIX 的工程實作承接這條脈絡，並不以回饋迴圈本身作為新穎性來源。

最接近本文主要比較的是 Olausson 等人的研究 [8]。該研究在 HumanEval 與 APPS 上比較自我修復與獨立重抽，明確把成本納入分析，發現修復增益依模型、資料與預算而變，部分條件下重抽具有相近或較高表現。本文將此問題放入具拒交語意、可見 / 隱藏測資隔離及簽章紀錄的交付流程，並報告事前設定規則下的複製結果。因此，本研究與既有結果形成可比較的延伸，而不能由某個 coding-agent 排行榜未列單次生成基準，推斷過去沒有人研究迴圈對照。

2.3 多代理信譽與相關錯誤

Kim 等人跨越 350 個以上模型的研究，發現不同模型的錯誤可以高度相關 [9]。這個結果提醒我們，增加模型或評審數量不自動等於增加獨立資訊。它不表示多數決必然失敗，也不能代替本系統中錯誤相關性的直接量測。

專題保存的三篇原文提供了更直接的設計對照。DRF 建立互評網絡、聲譽分數及基於上置信界的選擇策略 [10]；Ebrahimi 等人將合作回答視為反覆進行的互動，依過往貢獻調整可信度並用於聚合 [11]；He 等人的 A-Trust 則使用注意力訊號評估訊息及代理層級的可信性 [12]。這些工作分別處理參與者選擇、貢獻加權與訊息過濾。Vacant 在本文的主要比較中，則把交付閘門交給可執行測試。

差異在於裁決訊號與研究範圍，並不表示上述方法沒有外部評價來源，或 Vacant 已在它們的資料與攻擊設定中取得優勢。我們沒有實作三篇論文的完整同條件基準。尤其多方執行的金鑰多數決與多代理回答聚合，是兩種不同機制，不應因為都出現「多數」就交換結論。

2.4 可究責紀錄與研究透明性

PeerReview 透過安全日誌、見證及一致性檢查，使分散式節點的行為可被追查；其適用前提包含可重現的受監測狀態機行為 [13]。Vacant 不嘗試逐位元重現語言模型生成，而是保存實際候選，對指定測試重新執行。這是一種範圍較窄的產物驗收與事件核對，不能直接承接 PeerReview 的完整保證。

Certificate Transparency 以公開紀錄與一致性證明支援憑證活動稽核 [14]。Vacant 的線性簽章雜湊鏈借用可檢查日誌的設計原則，但不等於部署了 CT 的公開日誌、Merkle 證明或監視者生態。驗簽通過表示保存的事件可由該金鑰驗證，並不使事件內容自動成真。

Nosek 等人將預註冊定位為區分事前預測與資料生成後解釋的工具 [16]。本文使用版本控制保存分析規則與修訂歷程，並把探索性重放、事前設定比較與事後診斷分開報告。此做法增加可查核性，但不等同於第三方註冊平台的不可變時間戳，也不等同於 Registered Report 的事前同行評審。

表 1 彙整各研究脈絡與本文的關係。本文的研究缺口是特定交付架構下的效果辨識與證據保存，而不是聲稱相關領域不存在先行工作。

表 1 相關研究與本文的比較位置

研究脈絡	代表工作	本文承接內容	尚不能宣稱
測試與題庫	Barr ; HumanEval ; EvalPlus ; LiveCodeBench [1-4]	以可執行測資評估候選	測試等同完整需求；子集等同官方全庫
聚合與修復	Self-consistency ; Self- Debugging ; Reflexion ; Olausson [5-8]	取樣、聚合與失敗回饋的成本比較	迴圈首創；所有條件下修復勝過重抽
訊息與信譽	Kim ; DRF ; 可信度評分 ; A-Trust [9-12]	辨識相關錯誤與裁決訊號來源	已擊敗三篇方法；多數決必然無效
可究責紀錄	PeerReview ; CT [13-14]	簽署、連續性、外部核對的原則	繼承全部系統保證；鏈通過即內容真實
構念與方法	Körber ; Nosek [15-16]	區分心理構念、事前預測與事後解釋	已提升人類信任；已通過外部事前評審

本表比較設計與證據種類，不是不同論文之間的效能排名。

三 系統架構與可究責邊界

3.1 任務與交付的操作定義

對任務 i ，令 V_i 表示代理與交付流程可使用的可見驗收測資， GT_i 表示僅供事後評分使用的隱藏測資。模型可讀取題目敘述與公開輸入契約；修訂流程可以接收 V_i 的輸入、期望值、實際結果及錯誤訊息。 GT_i 不得進入候選選擇、修訂提示或提前停止條件。本文用 GT 簡稱隱藏測試評分依據，不主張它是真實需求的完整真值。

對一個被評估的任務與實驗臂，交付成功 Y_i 定義為 $accepted_i$ 與 $meets_demand_i$ 同時成立。 $accepted$ 表示實際放行； $meets_demand$ 表示保存的候選通過隱藏評估。拒交的 Y_i 為零，即使拒交後保存的候選碰巧通過隱藏測試，也不計為成功交付。假交付 F_i 則定義為已放行但未通過隱藏評估。本文假交付率的分母是該臂有效任務數，而不是已交付件數；兩個比率不能混用。

這組定義避免將大量拒交誤認為高品質，也避免把候選池內存在正解當成實際交付。整個系統的有效性仍以需求可被編譯為可執行驗收測資為條件。無法建立判定準則時，需要另外取得人工、契約或其他外部評價，本文沒有提供免費的替代裁判。

3.2 驗收與修訂流程

CONFORM 依序生成候選，對每份候選執行 V_i ，第一份通過者即放行並停止後續生成；預算耗盡仍未通過則拒交。H 系列也以可見驗收作為停止與出貨依據，但失敗後保留特定上下文，要求模型修訂。H-PI 保留較完整的互動脈絡；H-OC 加入計畫與靜態診斷；H-MIX 結合失敗回饋、靜態診斷、驗證指示、重複失敗偵測與較短的歷史脈絡。這些是受公開工具工作流啟發的本地實驗臂，並非原始產品的完整效能評比。[E1-E3]

三個 H 臂共用回饋格式、程式抽取與失敗分類原則、沙箱設定，以及拒交語意；第一輪與修訂輪的程式抽取差異另有記錄。這能減少部分實作差異，仍不是完整因子實驗。H-OC 的計畫、診斷與可用修訂次數同時改變，H-MIX 也同時改變多個部件，故不能單獨估計某一個提示句、計畫輪或記憶截斷的因果效果。




圖 1 可見驗收 隱藏評分與收據紀錄的資料流。GT 僅對保存的最終候選事後評分，不回流生成或出貨選擇。收據只涵蓋有加入記錄功能的實驗臂。

3.3 簽章事件鏈

Vacant 將驗收嘗試及裁決保存為事件。每筆事件包含串流識別碼、分支識別碼、遞增序號、前一筆事件雜湊、時間戳、事件類型、內容與 Ed25519 簽章。驗證者依固定 JSON 序列化規則重建簽章內容，檢查序號、串流及分支連續性，並使用公開金鑰逐筆驗章。事件被修改或鏈中間缺少資料時，既有連結與簽章可使不一致被發現。[E10]

此性質應稱為「竄改可被察覺」，而不是「事後不可能更改」。若驗證者沒有可信的既有鏈頭、外部見證或預期事件清單，持私鑰者仍可能另造一條鏈，或者只提供一段有效前綴。驗證保存的鏈也無法發現從未被寫入的事件。因此，鏈內完整性、事件語意正確性與整段歷史的完整性，是不同的證據要求。

本研究驗證的 194 條鏈涵蓋 R460R 的 CONFORM 與三個 H 臂，以及 R529 的 CONFORM 與 H-MIX。OFF、OFF5 不在這個簽章鏈總數的涵蓋範圍；它們的比較資料來自結果列及呼叫紀錄。不能把「9,841 筆全過」改寫成所有臂、所有網路呼叫均具獨立簽章證據。

3.4 多方執行與威脅模型

多方模式讓不同金鑰對同一份候選各自執行驗收、各自簽署結果，並依規則產生交付與異議紀錄。R453 在兩個作業系統環境上執行相同候選；R454 加入第三把金鑰，測試翻票及對同一事件簽署互相矛盾內容的情況。可觀察的對象是「哪一把金鑰簽了什麼」，不是「哪位自然人具有何種意圖」。[E9]

此機制依賴驗收套件適當、執行環境符合宣告條件，以及參與金鑰具有足夠獨立性。金鑰多數不等於獨立主體多數，更不自動具有抗 Sybil 能力。當多數金鑰串通，或全體使用同一套被破壞的驗收準則時，結果一致與鏈驗證成功仍可能伴隨錯誤交付。本文將這些情形列為設計邊界，而非宣稱簽章已消除它們。

四 研究方法

4.1 資料範圍與研究階段

本研究整合截至 2026 年 9 月 13 日的實驗紀錄，主體是 R460 初次六臂比較、R460R 五次同題庫新種子複製，以及 R529 跨題庫三臂比較。較早的候選池診斷、CONFORM 上線、同候選 EQ5 實驗與多方執行研究，提供機制形成及邊界驗證的背景。七段實驗彼此用途不同，不能把全部資料相加成一個樣本數。[E1-E9]

R460 與五次複製都使用本地 LCB v2 的 120 題，按六塊各二十題執行。新種子改變順序及框架的隨機選擇；題目集合沒有重新抽樣。因此，五次複製是同一批題目的重複測量，能檢查該題庫上的重現性，不能排除題庫特異性。種子亦不代表推論服務能逐位元重現模型輸出。

R529 使用四個互斥題目集：LCB v3 medium 135 題、LCB v3 hard 54 題、HumanEval+ 156 題與 MBPP+ 371 題，共 716 題。HumanEval+ 原始 164 題中八題、MBPP+ 378 題中七題依已登記的沙箱適用性規則排除。排除有事前紀錄，但仍改變推論母體。LCB v3 的題目日期全部不晚於 2024 年 8 月 10 日，不能宣稱晚於模型訓練截止或無資料污染。[E5-E6、E11]

4.2 實驗臂與成本控制

表 2 各實驗臂的決策與預算

臂	候選與交付規則	最大模型呼叫	所辨識的問題
OFF	一次生成後交付；隱藏測試只作事後評分	1	單次生成基準
CONFORM	依序生成；第一份可見通過即交付；耗盡則拒交	5；可早停	驗收與額外取樣的合併收益
OFF5	生成五份；依可見執行行為簽名多數選擇	5；固定	程式行為聚合基準
EQ5	同一組五份候選供驗收選擇與多數決使用	5；固定	固定生成成本後的選擇規則
H-PI	初稿後最多四次修訂；保留較完整脈絡	5；可早停	較簡單的回饋修訂
H-OC	計畫一次、初稿一次；最多三次修訂	5；可早停	包含計畫與診斷的組合

臂	候選與交付規則	最大模型呼叫	所辨識的問題
H-MIX	初稿後回饋修訂；診斷、驗證提示及重複失敗停止	5；可早停	主要受評估修訂流程

H 臂另有輪間 token 與時間預算。相同呼叫額度不等於相同實際成本。[E1-E3、E8]

核心模型在實驗紀錄中識別為 gemma-4-12b-it-qat，量化設定為 Q4_0；主要實驗使用同一模型家族及六個 persona。persona 是提示角色，不代表六個獨立訓練模型。呼叫紀錄使用溫度 0.7。本文保留模型檔及部署識別作為本次實驗條件，不以模型名稱推斷其全部訓練特性。[E1、E6]

H 臂上限為每題五次呼叫、32,000 token 與 900 秒的輪間停止預算；每次沙箱評估逾時為十秒。token 與牆鐘預算在呼叫之間檢查，因此不是每題消耗的嚴格上界。單次請求及重試可以跨過這個界線。H-OC 的計畫占用一次呼叫，減少可用修訂機會。CONFORM 可早停，OFF5 固定產生五份候選；各臂的實際 token、時間及呼叫數並不相等。[E1]

本文因此將 H-MIX 與 CONFORM 的比較稱為「相同最大呼叫額度下的工作流比較」。只有 EQ5 把兩個選擇規則作用在完全相同的五份候選上，才直接固定生成成本與候選品質。CONFORM 相對 OFF 同時改變取樣機會與出貨閘門，不能將其差值全歸因於驗收本身。

4.3 假設與事前方向

H1 為修訂流程相對單次生成提高交付成功率，分別比較 H-PI、H-OC、H-MIX 與 OFF。H2 為主要假設：H-MIX 在相同最大呼叫額度下，相對 CONFORM 提高交付成功率。H3 為固定候選集合後，驗收選擇相對行為多數決提高交付成功率，以 EQ5 的兩個選擇規則檢驗。H4 關注假交付，但方向依研究階段區分。[E1-E4、E8]

R460 的 P-H4 原先預測修訂增加可見測試過擬合風險，假交付會高於 CONFORM；觀察結果方向相反。R460R 才將 H-MIX 假交付較低列為後續 P-R4 的事前預測。本文不把後續方向回填成第一次實驗的原始假設。假設標號 H1 至 H4 是本文整理的議題層級，歷史預測 P-H、P-R 與 P-X 的原始名稱與裁決保留在各階段來源。[E2-E4]

4.4 配對估計與多重比較

配對單位是 `task_id`。比較臂 A 與 B 時，僅納入兩臂都有有效結果列的共同題目集合，令其大小為 n 。 b 表示 A 成功而 B 失敗的題數， c 表示 A 失敗而 B 成功的題數，交付差值為 $\Delta = 100(b - c)/n$ 個百分點。基礎設施失敗標為 `infra_void`，不直接當成模型失敗，並另報其數量及敏感度分析。

本研究使用雙尾精確 McNemar 檢定 [17]。在不一致對數 $d = b + c$ 固定且兩方向等可能的虛無假設下， $p = \min\{1, 2P[X \leq \min(b, c)]\}$ ，其中 X 服從 $\text{Binomial}(d, 0.5)$ 。R460 與每次 R460R 各自以三個 H 臂對 OFF 與 CONFORM 的六項檢定構成 Holm 家族；R529 以兩項主要比較構成家族，顯著水準為 .05 [18]。

原分析器將不一致對中的勝出機率以 Clopper-Pearson 二項區間估計，再依 $\Delta = 100(2\pi - 1)d/n$ 映射為差值區間 [19]。本文保留這個事前設定的條件區間，並標示未作多重比較調整。它對觀察到的不一致對數條件化，不應表述成處理所有取樣不確定性的無條件差值區間。研究自訂狀態依這個區間判定，其敏感性亦須一併揭露。

R529 將各題目集的不一致對數相加作主要檢定，在所設定的虛無假設下，數值與合併後的一次精確 McNemar 檢定相同。逐集列出 b 、 c 有助於看出異質性，但不是額外的後端校正。五次同題庫複製則不合併成 $n = 600$ ，不取平均效果冒充新實驗，也不將它們解讀為五個獨立題目樣本。每次家族的校正控制不等於已控制整個研究歷程中所有探索比較的錯誤率。

4.5 決策規則與預註冊範圍

R460 的 EFFECTIVE 必須同時滿足：相對 OFF 至少 +25 個百分點、相對 CONFORM 至少 +10 個百分點；兩項比較均通過所屬六項家族的 Holm 校正；包含作廢呼叫成本的每件正確交付 token 不高於 OFF5；假交付率不高於 CONFORM 加五個百分點。若相對 CONFORM 顯著，但未通過全部條件，列為 `COSTLY_BUT_REAL`。若依原條件區間，上界低於 +10 個百分點，列為 `RULED_OUT`；其餘列為 `INCONCLUSIVE`。[E1]

這些是本研究事前設定的決策標籤，不是通用學術等級。RULED_OUT 只針對 +10 個百分點的目標尺度，不表示零效應或等價。R529 使用另一組成本與顯著性規則，同名標籤不可互引。五次複製另預先設定「五次同號且至少四次 Holm 顯著」的穩定宣稱要求；未達時逐次報告。[E3、E5]

預註冊亦有範圍限制。R440P 是事後探索重放；R460 的後端拓撲修訂發生在部分結果已存在之後，雖未改變效果門檻與比較家族，仍屬執行偏離。R529 的主要規則在發射前固定，但分析器提交晚於首塊資料完成。版本紀錄可以呈現這些時間關係，不能證實研究者從未看過資料。[E1、E5-E7]

4.6 原始紀錄核對

本文的主要表格另以不匯入原分析器的程式，直接讀取保存的 rows.jsonl，重建交付成功、假交付、共同分母、b/c、精確 p 值及各次 Holm 校正。條件區間由二項累積分布反解重算。所有 194 條收據鏈亦以公開金鑰重新驗證序號、連結及 Ed25519 簽章。這次核對使用保存的評分標籤，沒有重新生成模型答案，也沒有重新執行每份程式以驗證隱藏評分。[E12]

五 實驗序列與結果

5.1 候選池診斷與研究方向修正

R440P 對兩批已保存的五候選資料進行零模型呼叫重放。單模型資料為 179 題，五份候選全錯的有 31 題；混合池資料為 147 題，全錯者有 22 題。至少一份候選正確的比例因此分別為 82.68% 與 85.03%。這是對既有候選池的探索性上限診斷，不是事前註冊的效果檢驗。[E7]

固定候選集合後，任何僅能從中選擇的規則都不能交付集合以外的正解。此陳述限定於該集合；重新取樣、換模型、修改提示或加入工具都可能產生不同候選。因此，修訂是改變候選的一種方法，不能稱為唯一能突破所有候選上限的方法。

同輪對選擇規則的診斷沒有提供穩定而大的額外改善，促使研究把焦點轉向回饋修訂。稽核也發現最初一個離線重放版本誤用隱藏標籤參與選擇，之後改為僅依可見資訊判定。這項修正是評估流程的缺陷處置，不應被寫成有效實驗的正向結果。

5.2 驗收重抽的初期交付結果

CONFORM 的早期評估顯示，驗收重抽相對單次生成的效果會依題庫而異。MBPP+ 371 題的合併評估差值為 +4.58 個百分點；LCB v2 的 r447 為 +19.17 個百分點，LCB v3 的 r461 為 +7.94 個百分點。這些結果支持在可見測試存在時，額外生成機會可透過驗收規則轉換為更多正確交付。[E8]

R445 的八項預測為七項命中、一項未命中；未命中的是區間半寬比預測更大。這涉及資料變異而不是效果方向，仍應保留。不同早期 run 之間存在題目重疊，特別是 r447 與 R460 使用相同的 120 題。因此這些數字是各自條件下的比較，不是互相獨立的跨題庫複製。初期報告也記錄在所檢查候選中未見「隱藏通過但可見失敗」的情形；部分題庫的隱藏測試本就包含可見測試，不能把此結果推廣為任意驗收閘門的無損保證。

5.3 固定候選的選擇規則比較

EQ5 對每題固定生成五份候選，再分別以可見驗收選擇與行為多數決選擇。兩個規則共享候選與生成成本，較直接地隔離選擇機制差異。表 3 列出原始階段結果；所有 p 值都是各階段報告的未校正值，不應視為一個新合併家族的顯著性結論。[E8]

表 3 EQ5 的同候選選擇規則比較

階段／題庫	驗收成功	多數決成功	b/c	Δpp	p 原始
r446 MBPP+	280/371	265/371	24/9	+4.04	.0135
r448 MBPP+	286/371	273/371	21/8	+3.50	.0241
r449b LCB v2	85/120	75/120	15/5	+8.33	.0414
r449c LCB v3	157/189	149/189	13/5	+4.23	.0963

各階段單獨報告，MBPP+ 兩次重用題目；不合併 n 或另作合併顯著性宣稱。來源 [E8]。

MBPP+ 兩次與 LCB v2 的點估計及原始檢定較支持驗收選擇；LCB v3 方向相同但未顯著。R446 對兩規則選到同份程式的比例預測為 40% 至 95%，實測僅 20.49%，原先先驗未被支持。產物不同也不必然代表正確性不同，故同選率只能說明程式選擇差異。

後續 R460R 中 CONFORM 對 OFF5 的比較為不同生成流程下的探索性比較，並非 EQ5 同候選重現。雖五次方向一致，只有三次原始 p 值小於 .05。因此本文保留 EQ5 的局部支持，同時不作「驗收在所有條件下穩定優於多數決」的廣泛宣稱。

5.4 多方執行的可核驗性

R453 在 Mac 與 Linux 各自執行 368 題、每題五份的保存候選，1,840 個候選的可見驗收標籤全部一致；兩條鏈皆通過驗證。此結果支持指定候選與兩個指定環境間的執行一致性。原預測中的一項窗口設定不當被保留為失敗，另加報修正後的描述，不回改原窗口。[E9]

R454 加入第三把受控金鑰 K3，讓其在真實執行後翻票或簽出矛盾證言。在可評估的翻票集合中，273/273 格將異議金鑰指向 K3；在 1,840 格中未誤指誠實金鑰；58/58 個可評估矛盾簽署格作廢 K3 證言後仍得到正確裁決。這是注入已知故障的有限測試，不是對未知攻擊的完備偵測率。套件腐化與多數串通的其他診斷，則顯示相同機制可以一致地放行錯誤候選。[E9]

5.5 R460 初次六臂比較

R460 的 120 題中，OFF 成功 70 題、CONFORM 85 題、OFF5 78 題、H-PI 91 題、H-OC 96 題、H-MIX 101 題。H-MIX 對 CONFORM 的不一致對為 22/6，差值 +13.33 個百分點，未調整條件區間為 [4.22, 19.46]，Holm 校正後 $p = .0112$ ，依原規則列為 EFFECTIVE。[E2]

R460 共九項列入計分的預測，六項命中、三項未命中。未命中項涉及實際呼叫數、假交付方向及 loader 結束比例。這些預測各有不同意義，不應只用一個命中率概括全部假設。H-MIX 假交付為 14/120，CONFORM 為 29/120，與原本預期修訂增加假交付的方向相反。

這次實驗遇到兩次後端失敗，原先分兩端執行的設計改為單一後端完成；失敗塊保存為作廢資料，未納入主分析。部分塊較晚執行，也因此保留時間與負載差異。原始 +13.33 的觀察值得複製，但不能單由一次六臂實驗判定穩定效益。

5.6 R460R 同題庫五次複製

表 4 列出初次實驗及五次複製的交付率；表 5 列出 H-MIX 相對 CONFORM 的配對效果。第五次有七筆臂層級的基礎設施作廢，故逐臂分母不同，主比較共同分母為 116，不能直接以兩臂各自百分比相減替代配對差值。[E4、E12]

表 4 初次實驗與五次複製的交付成功

臂	R460	r1	r2	r3	r4	r5
OFF	70/120 58.33%	69/120 57.50%	65/120 54.17%	69/120 57.50%	62/120 51.67%	61/119 51.26%
CONFORM	85/120 70.83%	86/120 71.67%	87/120 72.50%	90/120 75.00%	85/120 70.83%	83/117 70.94%
OFF5	78/120 65.00%	73/120 60.83%	74/120 61.67%	71/120 59.17%	80/120 66.67%	81/118 68.64%
H-PI	91/120 75.83%	92/120 76.67%	95/120 79.17%	91/120 75.83%	97/120 80.83%	85/120 70.83%
H-OC	96/120 80.00%	92/120 76.67%	88/120 73.33%	90/120 75.00%	94/120 78.33%	90/120 75.00%
H-MIX	101/120 84.17%	93/120 77.50%	92/120 76.67%	91/120 75.83%	88/120 73.33%	89/119 74.79%

每格依序為正確交付件數 / 有效題數與百分比。r5 分母依臂不同；各次配對另取共同題目。來源 [E2、E4、E12]。

表 5 H-MIX 相對 CONFORM 的配對效果

階段	共同 n	b/c	Δ pp	95% 條件區間	Holm p	原規則狀態
R460	120	22/6	+13.33	[4.22, 19.46]	0.0112	EFFECTIVE
r1	120	15/8	+5.83	[-2.79, 12.89]	0.6301	INCONCLUSIVE
r2	120	17/12	+4.17	[-5.35, 12.80]	0.9165	INCONCLUSIVE
r3	120	12/11	+0.83	[-7.44, 8.89]	1.0000	RULED_OUT
r4	120	13/10	+2.50	[-5.94, 10.28]	0.6776	INCONCLUSIVE
r5	116	14/9	+4.31	[-4.54, 12.01]	0.9224	INCONCLUSIVE

每次家族為六。區間未作多重比較調整；狀態沿用當次預註冊，RULED_OUT 指 +10 pp 目標，並非零效應或等價。來源 [E2、E4、E12]。

五次 H-MIX 相對 CONFORM 的差值均為正，但零次通過 Holm 校正，未達到事前設定的穩定宣稱規則。各次未調整區間皆與 R460 區間相交，但上界都低於 R460 的 +13.33 點估計；這是描述性比較，既不是差異檢定，也不能證明原始估計必然上偏。較合理的解讀是初次效果可能受選擇後高估影響，而後續資料未確立相同尺度的修訂增益。

三個 H 臂相對 OFF 的十五個比較均通過各次六項家族的 Holm 校正；三個 H 臂相對 CONFORM 的十五個比較則全未通過。CONFORM 相對 OFF 的探索性配對差值依次為 +14.17、+18.33、+17.50、+19.17 與 +18.97 個百分點。這支持「驗收加重抽已取得大部分觀察到的改善」的描述，但不構成精確的因果中介比例。




圖 2 初次實驗與五次複製的主要配對效果。r1 至 r5 皆重用相同 120 題；r5 主比較共同分母為 116。每次各自進行六項 Holm 校正；圖中區間未作多重比較調整。來源 [E2、E4、E12]。

假交付方面，H-MIX 五次依序為 20/120、14/120、19/120、21/120、19/119，CONFORM 則為 26/120、26/120、23/120、25/120、25/117。五次方向都較低，支持後續 P-R4 的方向性預測；本段未另外為假交付配置新的確認性檢定。其他預測中， Δ 大於零為 5/5、至少 +10 個百分點為 0/5、Holm 顯著為 0/5、token 成本比率達窗為 3/5。

預先功效分析對 +10 個百分點的情境估計只有 .43 至 .63，故單次未顯著不等於效果不存在。這些功效值依設計假設而定，不能用五次零顯著直接反推真實效果，更不能忽略同題目與不同負載之間的相關性。第五次作廢列的已報最壞情境分析，使 H-MIX 對 CONFORM 的差值落在 [+0.83, +7.50]；其方向不變，但效果幅度仍受缺失處理影響。[E3-E4]

5.7 R529 跨題庫評估

跨題庫主比較包含四個互斥題目集的 716 題。表 6 的成功件數可重現原始記錄，但其絕對比例是兩種推論模式的混合結果，不能脫離此條件用於模型排行榜或與各外部題庫論文直接比較。[E6、E12]

表 6 跨題庫交付件數與 H-MIX 相對 CONFORM 的差值

題目集	n	OFF	CONFORM	H-MIX	b/c	Δ pp
LCB v3 medium	135	115	125	126	6/5	+0.74
LCB v3 hard	54	38	41	43	5/3	+3.70
HumanEval+	156	129	147	148	5/4	+0.64
MBPP+	371	277	295	299	15/11	+1.08
合併	716	559	608	616	31/23	+1.12

OFF、CONFORM、H-MIX 欄為成功件數，分母為同列 n。兩後端為不同推論模式，絕對值屬混合條件；不得單獨作模型排名。主要 Holm p 為 H-C .3409、H-O 2.02×10^{-8} ，家族為二。來源 [E6、E12]。

H-MIX 對 CONFORM 的合併不一致對為 31/23，差值 +1.12 個百分點，Holm 校正後 $p = .3409$ ，主假設未成立。對 OFF 則為 79/22，差值 +7.96 個百分點，校正後 $p = 2.02 \times 10^{-8}$ 。四集 H-MIX 對 CONFORM 的未校正雙尾 p 值分別為 1.000、.727、1.000、.557，均未顯著。R529 依自身規則列為 INCONCLUSIVE，不將四集方向為正當成修訂效益已複製成功。

R529 的八項預測四項命中、四項未命中。偏離主要出現在成本與迴圈形狀：許多題目第一輪即通過可見驗收，使實際呼叫數低於預期，單次輸出成本卻未相同比例下降。假交付亦未呈現全面改善：LCB medium 為 H-MIX 6/135 對 CONFORM 9/135，hard 為 7/54 對 11/54，HumanEval+ 均為 6/156，MBPP+ 則為 58/371 對 56/371。因此，同題庫五次假交付較低的方向，不能直接外推為所有題庫都較低。

收官後發現兩個後端雖使用相同模型檔，推論服務版本卻分別啟用與未啟用 reasoning。塊內同題的各臂使用同一後端，使配對算術仍可重算，也減少固定後端差異的混淆；但不排除後端模式與工作流的交互作用。合併結果估計的是這個混合條件下的平均差異，不是已校正為單一推論模式的效果。修正後的程式設定不能追溯改變先前資料。

5.8 量具與紀錄驗證結果

R460R 三十塊與 R529 三十七塊的 V/GT v2 稽核均未報告違規。這裡的「零」是工具定義與涵蓋範圍內的未偵測結果。R460R 前三次共有 95,090 個候選比對項，其中實際檢查 57,248 個，37,842 個因字面值過短或瑣碎而跳過，約占 39.8%。工具主要掃描 H 臂，其餘臂的覆蓋依獨立掃描或人工抽查而異。[E4、E6]

量具 v1 曾在 R460 產生九十筆偽陽性。v2 依訊息來源及有限回聲豁免收窄判準，並以人工植入的隱藏內容、錯誤 task_id 與原始驗收碼進行故障注入。這些測試可檢查已知違規形式是否會被抓到，尚未量得自然發生洩漏的敏感度，也不涵蓋所有語意改寫或間接資訊流。

收據驗證結果與 V/GT 結果分開呈現。194 條鏈、9,841 筆事件均通過本次逐筆驗簽及連結檢查；這重現保存紀錄的密碼學一致性，而不是驗證模型答案的真實正確性。鏈總數包括 R460R 的 120 條與 R529 的 74 條，筆數分別為 6,674 與 3,167。[E10、E12]

六 討論

6.1 增益主體與推論尺度

本研究最穩定的結果是：在已具有可執行驗收測試的設定中，加入驗收與額外嘗試的工作流，相對單次直接交付有較高成功率。五次複製中 CONFORM 對 OFF 的改善幅度，已接近加入修訂後的整體改善；H-MIX 相對 CONFORM 的主比較未達顯著。工程上，這支持先確認測資品質、拒交語意與重抽基準，再判斷是否需要更複雜的修訂流程。

這個推論與 Olausson 等人對成本控制下修復收益不穩定的觀察相容 [8]，但不能稱為對其效果數值的直接複製，因為模型、題庫、回饋來源及停止規則不同。它也不反駁 Self-Debugging 與 Reflexion 在各自條件下的改善 [6-7]。工作流收益取決於可見測試提供多少可用資訊，以及相同預算的重抽已能解決多少失敗。

既有離線分析比較 H 臂第一輪與最終結果，對理解何時進入修訂有幫助；然而第一輪和最終結果並非隨機指派的獨立處置，且重跑沙箱的時間限制會引入少量不一致。本文因此把此類分解視為描述性診斷，不以「迴圈只救不傷」推導在一般情境下不可能破壞原有正解。

6.2 驗收品質是共同前提

可見測試同時提供選擇標準與修訂訊號。這能引導模型修正可觀察錯誤，也可能使候選集中迎合少數案例。當第一輪即通過寬鬆的可見測試，CONFORM 與 H-MIX 都會早停，隱藏失敗就不會觸發修訂。R529 中部分高放行環境與小額增量，與這種機制限制相容；要驗證其因果作用，仍需操弄測試覆蓋的實驗。[1、3]

可見驗收不應被視為完整規格的等價物。沙箱限制、安全性、效能、維護性與使用者意圖，也未因功能測試通過而全部被評估。尤其目前沒有把撰寫、校驗及維護測資的人工成本納入 token 指標。本文量到的是「已有測資時」的交付效果，尚未量到從模糊需求開始的端到端經濟效益。

6.3 紀錄可驗證與內容正確的分離

簽章紀錄的價值，在於讓一份交付結論能連回特定候選、驗收事件與金鑰。這使得事後可以檢查事件連結是否一致、哪一把金鑰提出異議，以及保存的資料能否重算既有裁決。它沒有提供人類法律責任的自動認定，也沒有讓擁有私鑰者無法說謊。

多方測試進一步說明這個區別：一把受控金鑰的翻票可在指定條件下被指認，但同一套錯誤規格能使多方一致產生錯誤結論。PeerReview 與 CT 的文獻提供可核驗紀錄的設計基礎 [13-14]，不應被引用為 Vacant 已具備所有同類系統保證的替代證據。

6.4 研究貢獻的適當強度

以正式論文的標準，本文不將最高一次交付率當作核心突破。較具體的價值在於三項可檢查的產出：把候選生成、驗收選擇與修訂增量拆成可對照的研究問題；以五次重複測量及題庫結果限制初次顯著的解釋；使分析規則、作廢處理、量具缺陷與宣稱降級具有可追溯紀錄。

將原先受到支持的主張降為未確立，不是額外的效能證據，而是推論品質的要求。R460的結果仍是該次實驗的觀察值，不應被刪除；後續複製也不能只被描述成「沒有成功」而省略其方向與區間。完整報告兩者，使讀者能區分存在改善的線索、實務尺度的未達成，以及還不足以支持穩定增量的證據。

6.5 與學術研究流程的對照

表 7 研究程序與尚未完成的要求

程序	已完成與證據	哪裡未做到
事前假設	主要門檻、家族、停止規則保存於版本紀錄 [E1、E3、E5]	R440P 為探索；H4 方向分階段不同
事前分析	多數判準已有機器可讀欄位及檢查	R529 分析器晚於首塊完成；未讀資料不可獨立證實
效果與不確定性	主表列分母、配對、效果、區間與 Holm p [E12]	條件區間未校正；不能代表全研究家族控制性
複製	同題庫五次新種子；跨題庫四集 [E4、E6]	重用題目；單模型；後端負載與模式不同
重算	歷史三方核對；本文另一路徑重算 [E12]	同專案資料核對，不是外部獨立複製
量具驗證	人工故障注入、回歸及鏈驗簽 [E9-E10]	未驗證自然洩漏偵測率；掃描有跳過項
資料可得性	保存結果列、呼叫、收據及索引 [E11]	部分題庫需另取得；未全符合統一證據包格式
偏離與負向結果	保留作廢塊、事故及主張降級 [E1-E6]	缺少外部事前評審與第三方不可變註冊

預註冊與透明報告支援可查核性，不能替代實驗效度或外部審查 [16]。

這份對照不是以完成項數替研究打分，而是標示哪一個程序支持哪一個推論。獨立程式重算能降低同一分析器錯誤被重複採用的風險，卻不能替代外部研究團隊的獨立複製。版本控制能保存偏離紀錄，卻不能自行保證資料從未被預覽。方法上的透明性應與方法上的不足一併呈現。[16]

七 效度威脅與限制

7.1 單一模型與有限任務形式

主要 harness 結果來自單一 12B 量化模型與 Python 題庫。persona、端點或重複執行不構成模型家族多樣性。本文尚不能推論至較大模型、不同量化、其他程式語言、長期工具使用或真實軟體專案維護。

7.2 驗收測資不完整代表需求

評估必須依賴有限測試。LCB v3 部分题目的隱藏測試數量與參考解覆蓋較弱；題庫選擇與沙箱排除也形成研究者設定的適用範圍。測試可發現指定失敗，不能證明未測行為正確。無法排除訓練資料污染，使對外部新任務的泛化推論更受限制。

7.3 同題庫複製的相關性

五次複製重用完整 120 題，不能排除這些題目特別適合或不適合某一種工作流。相同模型、相同任務與共享後端亦可能使各次結果相關。五次同號不應被當成九次或五次獨立擲幣的證據，不能直接套用獨立符號檢定。

7.4 檢定力與區間方法

既有 $n = 120$ 設計對 +10 個百分點的功効有限，對更小差值更不足。R460R 的未顯著不證明等價，R529 的正向小差值也不證明實務收益。本文保留原條件區間與狀態，未將其改寫為普遍有效的差值區間；例如 r4 的上界 10.28 與 +10 門檻很近，狀態計數不宜承擔主要論證。

7.5 後端模式與負載差異

R529 混合 reasoning 與非 reasoning 後端，R460R 各次亦有不同共租負載與第五次模型重載事故。逐題同後端配對減少一部分差異，但不能消除臂執行順序、延遲、截斷及推論模式交互作用。本文未把 workflow 效果與部署效應完全分離。

7.6 缺失資料與成本不對稱

complete-case 分析排除未完成的臂列，而不同 workflow 曝險於較多呼叫，基礎設施失敗可能不是隨機缺失。已報最壞界只處理特定成功率比較，不能取代所有缺失機制的分析。相同最大呼叫數亦不是相同 token、時間、能源或人工成本。

7.7 量具的涵蓋範圍

V/GT 掃描依賴字面比對、訊息來源分類及豁免規則，會跳過部分瑣碎項目；人工抽查範圍也不足以構成全量資訊流驗證。故障注入確認的是已知例子可被偵測，尚未建立自然洩漏事件的靈敏度、特異度或語意洩漏覆蓋率。

7.8 金鑰與記錄完整性

簽章指向金鑰，不自動指向獨立人員或組織。保存鏈的驗證不證明歷史沒有被截短、私鑰從未外洩，或簽署環境未被控制。受控三方試驗不能作為任意拜占庭攻擊、金鑰偽裝或多數串通的防禦保證。

7.9 研究獨立性與資料公開程度

研究設計、系統實作與原始稽核由同一專案組織，沒有外部團隊的獨立複製。部分分析與後端設定在資料存在後修正，雖有紀錄，仍增加研究者自由度。題庫封裝未全部公開再散布，完整評分重放需要相同版本及適用授權；G 系列資料也未全部包成專案統一 RECORD_SPEC 證據包。因此，公開結果列可重算與完整環境可重建應分別表述。

八 結論與後續研究

本文在需求已具可執行測資的程式任務中，比較單次生成、驗收重抽、多數決與修訂流程。五次同題庫複製顯示修訂流程相對單次生成有穩定的方向與各次校正後證據，但驗收重抽已取得大部分觀察到的改善。主要 H-MIX 對 CONFORM 的五次差值皆為正，零次通過 Holm 校正；跨題庫主比較亦未顯著。現有證據因此支持把驗收、重抽及拒交語意作為交付流程的基礎，尚不足以確立修訂的額外效益。

可究責紀錄為這些交付與驗收事件提供可核驗的連結。本次重新驗證 194 條鏈的 9,841 筆事件全部通過，但這是已保存紀錄的簽章與連續性結果，不是完整需求、全部歷史或自然人責任的證明。論文將兩種證據分開，是為了讓系統品質與紀錄品質都能被具體檢查。

下一階段最有辨識力的實驗，是固定模型檔、推論服務版本與 reasoning 設定，並以同一批基礎候選比較不同驗收品質。可預先操弄測試數量、邊界覆蓋與錯誤期望值比例，交叉比較 CONFORM 與 H-MIX，事前設定最小實務差值及成本尺度。這能直接回答額外回饋在何種測資條件下比重抽更有用。

另一條研究線應評估紀錄的使用價值：讓外部研究者在不依賴原分析器的情況下重建裁決，並測量加入可信鏈頭或外部見證後，對截短、分叉及漏記的可察覺性。若未來要研究人類依賴或信任，則須另行設計使用者研究，測量決策、查核時間與依賴校準。這些問題尚未完成，不以目前的測試通過率代替。

資料與程式可取得性

本文資料來源為 Vacant 儲存庫 <https://github.com/cosmopig/Vacant>，分析基準提交為 44be37fe52bac148ecd2835aa384c804c612ffea。實驗原始列、呼叫紀錄、公開金鑰、收據及階段判定依附錄 A 索引定位。本文新增的主表重算程式 `verify_evidence.py` 與 `verified_evidence.json` 保存於 docs/paper_2026-09-14。重算不發出模型請求；完整候選重評仍需要適用的題庫版本與沙箱環境。本文沒有重跑新的模型實驗。

研究透明性聲明

本研究包含研究團隊使用 AI 代理進行實作、查核與寫作輔助的過程。原專案中不同代理的分工屬專案內查核，本文的另一路徑重算亦屬同一研究資料的驗證，不稱為外部同行評審。研究者同時為系統開發者，對系統成果具有直接投入；本文因此保留負向結果、未顯著比較與程序偏離。參考文獻提供方法基礎與比較脈絡，本文的效果主張則由自己的實驗資料支持。

參考文獻

- [1] E. T. Barr, M. Harman, P. McMinn, M. Shahbaz, and S. Yoo. “The Oracle Problem in Software Testing: A Survey.” *IEEE Transactions on Software Engineering*, 41(5), 507-525, 2015. DOI: 10.1109/TSE.2014.2372785. <https://discovery.ucl.ac.uk/id/eprint/1471263/>
- [2] M. Chen et al. “Evaluating Large Language Models Trained on Code.” arXiv:2107.03374v2, 2021. <https://arxiv.org/abs/2107.03374v2>
- [3] J. Liu, C. S. Xia, Y. Wang, and L. Zhang. “Is Your Code Generated by ChatGPT Really Correct? Rigorous Evaluation of Large Language Models for Code Generation.” *Advances in Neural Information Processing Systems*, 36, 2023. <https://arxiv.org/abs/2305.01210v3>
- [4] N. Jain, K. Han, A. Gu, W.-D. Li, F. Yan, T. Zhang, S. Wang, A. Solar-Lezama, K. Sen, and I. Stoica. “LiveCodeBench: Holistic and Contamination Free Evaluation of Large Language Models for Code.” arXiv:2403.07974v2, 2024. <https://arxiv.org/abs/2403.07974v2>
- [5] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou. “Self-Consistency Improves Chain of Thought Reasoning in Language Models.” *International Conference on Learning Representations*, 2023. <https://arxiv.org/abs/2203.11171v4>
- [6] X. Chen, M. Lin, N. Schärli, and D. Zhou. “Teaching Large Language Models to Self-Debug.” arXiv:2304.05128v2, 2023. <https://arxiv.org/abs/2304.05128v2>
- [7] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao. “Reflexion: Language Agents with Verbal Reinforcement Learning.” *Advances in Neural Information Processing Systems*, 36, 2023. <https://doi.org/10.52202/075280-0377>
- [8] T. X. Olausson, J. P. Inala, C. Wang, J. Gao, and A. Solar-Lezama. “Is Self-Repair a Silver Bullet for Code Generation?” *International Conference on Learning Representations*, 2024. <https://arxiv.org/abs/2306.09896v5>
- [9] E. M. Kim, A. Garg, K. Peng, and N. Garg. “Correlated Errors in Large Language Models.” *Proceedings of the 42nd International Conference on Machine Learning*, PMLR 267, 30038-30066, 2025. <https://proceedings.mlr.press/v267/kim25e.html>
- [10] Y. Lou, H. Hu, S. Ma, Z. Zhang, L. Wang, J. Ge, and X. Tao. “DRF: LLM-AGENT Dynamic Reputation Filtering Framework.” arXiv:2509.05764v1, 2025. <https://arxiv.org/abs/2509.05764v1>
- [11] S. Ebrahimi, M. Dehghankar, and A. Asudeh. “An Adversary-Resistant Multi-Agent LLM System via Credibility Scoring.” *Proceedings of IJCNLP-AAACL*, 1676-1693, 2025. DOI: 10.18653/v1/2025.ijcnlp-long.90. <https://aclanthology.org/2025.ijcnlp-long.90/>
- [12] P. He, Z. Dai, X. Tang, Y. Xing, H. Liu, J. Zeng, Q. Peng, S. Agrawal, S. Varshney, S. Wang, J. Tang, and Q. He. “To trust or not to trust: Attention-based Trust Management for LLM Multi-Agent Systems.” arXiv:2506.02546v2, 2026. <https://arxiv.org/abs/2506.02546v2>
- [13] A. Haeberlen, P. Kouznetsov, and P. Druschel. “PeerReview: Practical Accountability for Distributed Systems.” *Proceedings of the 21st ACM Symposium on Operating Systems Principles*, 175-188, 2007. DOI: 10.1145/1294261.1294279. Author technical report: <https://www.mpi-sws.org/tr/2007-003.pdf>
- [14] B. Laurie, E. Messeri, and R. Stradling. “Certificate Transparency Version 2.0.” RFC 9162, 2021. <https://www.rfc-editor.org/rfc/rfc9162.html>

- [15] M. Körber. "Theoretical Considerations and Development of a Questionnaire to Measure Trust in Automation." Author preprint for the 20th Congress of the International Ergonomics Association, 2018. <https://doi.org/10.31234/osf.io/nfc45>
- [16] B. A. Nosek, C. R. Ebersole, A. C. DeHaven, and D. T. Mellor. "The Preregistration Revolution." *Proceedings of the National Academy of Sciences*, 115(11), 2600-2606, 2018. <https://doi.org/10.1073/pnas.1708274114>
- [17] Q. McNemar. "Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages." *Psychometrika*, 12, 153-157, 1947. <https://doi.org/10.1007/BF02295996>
- [18] S. Holm. "A Simple Sequentially Rejective Multiple Test Procedure." *Scandinavian Journal of Statistics*, 6(2), 65-70, 1979. <https://www.jstor.org/stable/4615733>
- [19] C. J. Clopper and E. S. Pearson. "The Use of Confidence or Fiducial Limits Illustrated in the Case of the Binomial." *Biometrika*, 26(4), 404-413, 1934. <https://doi.org/10.1093/biomet/26.4.404>

附錄 A 內部研究證據索引

本文以數字編號引用外部研究，以 E 編號定位專案證據。下列檔案均相對於上列儲存庫根目錄；引用收官檔時，以最後補記及更正後狀態為準。既有檔案中的歷史指示是研究過程資料，不改變本文的研究範圍。

[E1] R460 事前設計與拓撲修訂

[DECISION_20260907_R460_HARNESS_PREREG.md](#)

[E2] R460 初次結果與更正

[DECISION_20260911_R460_FABLE_AUDIT_HARNESS.md](#)

[E3] 五次複製的事前規則

[DECISION_20260911_R460R_FIVE_REPLICATIONS_PREREG.md](#)

[E4] 五次複製完整收官，以第八節補記為準

[DECISION_20260912_R460R_FABLE_AUDIT_REPLICATIONS.md](#)

[E5] R529 跨題庫事前規則

[DECISION_20260911_R529_CROSS_BANK_PREREG.md](#)

[E6] R529 收官與後端模式更正，含第十一至十三節

[DECISION_20260912_R529_FABLE_AUDIT_CROSS_BANK.md](#)

[E7] 候選池的探索性重放

[DECISION_20260903_R440P_CONFORMANCE_GATE.md](#)

[E8] CONFORM 與 EQ5 階段結果

[CONCLUSION_20260904_R445_CONFORM_SETTLEMENT.md](#)

[CONCLUSION_20260904_R446_EQUAL_BUDGET.md](#)

[DECISION_20260907_R449C_FABLE_AUDIT_UNRESOLVED.md](#)

[docs/VACANT_COMPLETE_2026-09-12.md](#)

[E9] 多方執行與攻擊邊界

[DECISION_20260906_R453_FABLE_AUDIT_REAL_MULTIPARTY.md](#)

[DECISION_20260906_R454_FABLE_AUDIT_NAMED_DISSENT.md](#)

[DECISION_20260905_R449_PEEREXEC_ARCHITECTURE_AUDIT.md](#)

[E10] 簽章格式與原始驗簽報告

[vacant/logbook.py](#)

[vacant/canonical.py](#)

[ops/gain/replay/r460r/receipts_verify.json](#)

[ops/gain/replay/r460r/receipts_verify_r4r5.json](#)

[ops/gain/replay/r529/receipts_verify.json](#)

[E11] 題庫、歷程與實作索引

[runs/INDEX.md](#)

[vacant/codebench.py](#)

[docs/JOURNEY_2026-09-13.md](#)

[docs/HMIX_ARCHITECTURE_2026-09-11.md](#)

[E12] 本文從結果列及公開簽章重新核對的程式與輸出

[docs/paper_2026-09-14/verify_evidence.py](#)

[docs/paper_2026-09-14/verified_evidence.json](#)

附錄 B 重要事故與推論影響

表 B1 研究事故的處置與剩餘影響

事件	已採取處置	推論影響
R440P 重放誤用隱藏標籤	改為僅用可見資訊選擇；保留更正 [E7]	屬失效分析版本，不能作有效交付證據
R460 後端兩次崩潰	作廢塊隔離；改端點完成剩餘塊 [E1-E2]	拓撲在部分結果存在後修訂；執行時間不同
V/GT v1 九十筆偽陽性	依來源建立 v2；配合已知故障注入 [E2、E4]	降低噪音但新增豁免；零命中依賴覆蓋範圍
R460R 共租與併發假警報	揭露共租；以完成時刻減延遲重建窗口 [E4]	仲裁值未變；負載差異仍存在
排程器中文字串解碼失敗	修正解碼及截斷處理 [E6]	造成排程停頓；非模型錯誤
r5 模型崩潰與自動卸載	修正重載策略；七筆作廢另列 [E4、E6]	不同臂分母；需要缺失敏感度分析
R529 後端 reasoning 不一致	補探針與描述欄；後續固定設定 [E6]	歷史資料仍為混合模式，不能追溯同質化

處置修復執行或量具，不使已存在的設計限制消失。

這些事故中，有些改變觀測條件，有些只改變分析器或記錄讀取。本文保留這項區分：重新計算後仲裁值相同，表示特定修正沒有改動該組數值；不代表整個研究已排除所有部署偏差。

附錄 C 引用與主張邊界

表 C1 文獻與實驗各自能支持的主張

主張	可用依據	本文採取的界線
回饋修訂有研究基礎	Self-Debugging、Reflexion [6-7]	承接既有工作；不主張首創
修復不一定優於重抽	Olausson [8]；R460R、R529	外部研究支持問題的重要性；本文效果靠自己的配對資料
多代理可能一起出錯	Kim [9]	不將相關錯誤改寫成所有投票必然無效
驗收可改善候選選擇	EQ5；CONFORM 對照 [E8]	同候選局部證據；不外推所有測資與模型
H-MIX 額外收益已穩定	現有複製未達事前規則 [E4、E6]	不採用此主張；保留差值、區間及未顯著結果
簽章使紀錄可核驗	PeerReview、CT 原則；逐筆驗簽 [13-14、E12]	限定鏈內一致性；不等於內容真實或完整歷史
系統提高人類信任	需要構念與使用者測量 [15]	本文未測量，不作成效主張
研究遵守全部學術要求	表 7 的已完成與缺口	不以內部查核冒充外部同行評審

書目以原始研究、官方論文頁或作者稿為主。文獻整理屬主題式回顧，未執行系統性綜述的窮盡檢索。

附錄 D 可重算範圍

verify_evidence.py 從 R460 六塊、R460R 三十塊及 R529 三十七塊的結果列重建主表。每次六臂比較重新建立六項 Holm 家族，跨題庫主比較建立兩項家族。程式也對 R460R 與 R529 的 194 條公開收據鏈逐筆驗章，將鏈頭與檔案 SHA-256 寫入 verified_evidence.json。檢查不匯入既有分析器，也不讀取私鑰。

其驗證對象是保存的布林評分、配對算術與簽章紀錄。它不重新執行全部候選、不重現生成、不證明私有題庫測試充分、不重新估計 V/GT 量具覆蓋率，也不驗證所有歷史探索實驗的每一個數字。其他階段結果依附錄 A 所列收官檔引用，與本文重算的主要結果明確區分。